

Reconocimiento de Señales de Tránsito

Reto 3 — GTSRB

Manuela Alexandra Correa Gutiérrez · 55222509

Yeimy Andrea Martínez Arévalo · 55222502

Andrés Santiago Lancheros Ortiz · 55222522



¿Por qué reconocer señales de tránsito en tiempo real?

Contexto


Una startup de movilidad necesita un **módulo de asistencia a la conducción** capaz de identificar señales de tránsito de forma autónoma. El sistema debe ejecutarse en un **dispositivo embebido** (S. computacional para una tarea específica), lo que impone restricciones severas de tamaño y velocidad.

Restricciones críticas

- Reconocimiento **en tiempo real** con latencia mínima
- Modelo **ligero y eficiente**
- **Alta precisión**: un fallo puede provocar un accidente

Objetivo del proyecto

Entrenar una CNN (Red Neuronal Convolutiva) capaz de clasificar correctamente las **43 categorías** del dataset GTSRB con la máxima precisión posible.



Dataset GTSRB: German Traffic Sign Recognition Benchmark

39.209

Imágenes de entrenamiento

Descargadas desde Kaggle con kagglehub

12.631

Imágenes de test

Conjunto de evaluación final


43

Clases de señales

Desde límites de velocidad hasta señales de prohibición

Hallazgos del análisis exploratorio (EDA)

- **Desbalance de clases:** algunas categorías tienen ~200 imágenes y otras superan las 2.000
- **Resolución variable:** la mayoría de imágenes originales miden entre **25 px y 50 px**
- Se incluyen 45 archivos de metadatos con información por clase



Transformación de los datos para el modelo

01

Conversión de color BGR → RGB

(Blue-Green-Red) - Estándar de Colores imágenes digitales.

Necesaria para que los canales de color correspondan con la representación estándar.

02

Redimensionamiento a 32 × 32 px

Unifica todas las imágenes a un tamaño fijo, imprescindible para procesar lotes en la CNN.

Modelo ligero y costo computacional reducido.

03

Normalización de píxeles [0, 1]

División de valores: $B \frac{255-1}{255}$ $G \frac{128-0.5}{128}$ $R \frac{0-0}{255}$

Escalar los valores facilita la convergencia y estabiliza el aprendizaje de la red.

04

One-hot encoding (43 clases)

Forma de representar categorías numéricamente

Requerido por la función: `categorical_crossentropy`.

División del dataset

El conjunto original de Train se dividió en tres particiones:

Train – 60%

23.525 imágenes

Validación – 20%

7.842 imágenes

Test – 20%

7.842 imágenes

Calidad de los datos antes del entrenamiento

1

Revisión visual aleatoria

Se inspeccionaron imágenes del conjunto Train para comprender su contenido visual, variabilidad de condiciones lumínicas y calidad general.

2

Verificación de legibilidad

Se comprobó que las **39.209 imágenes** de Train fuesen legibles. Resultado: **0 imágenes ilegibles**. El dataset está completo e íntegro.

3

Detección de duplicados

No se encontraron duplicados por nombre de archivo. Todos los registros son únicos en el conjunto de entrenamiento.

4

Outliers de tamaño

Se detectaron 3.950 imágenes con resoluciones atípicas mediante el método IQR. Se decidió conservarlas, ya que el proceso de redimensionamiento aplicado durante el preprocesamiento normaliza sus dimensiones.

- ✓ El análisis reveló variabilidad de resolución, pero en lugar de eliminar datos, se optó por estandarizarlos en el preprocesamiento, preservando el máximo de información.

Red Neuronal Convolutacional (CNN)

¿Por qué una CNN?

Las CNN son la arquitectura de referencia en visión por computador. Detectan automáticamente **bordes, formas y patrones de color**, características esenciales para distinguir señales de tránsito.

Hiperparámetros

- Optimizador: **Adam**
- Loss: **categorical_crossentropy**
- Métrica: **accuracy**
- EarlyStopping: patience=5

📄 Parámetros entrenables totales: **164.651** – modelo compacto e ideal para dispositivos embebidos.

Arquitectura de la red



Entrada + 3 Bloques Convolucionales

32 → 64 → 128 filtros con BatchNormalization y MaxPooling2D en cada bloque



Flatten + Dense(128)

Aplana el mapa de características y conecta a una capa densa de 128 neuronas con activación ReLU



Dropout(0.5) + Softmax(43)

Regularización con dropout para evitar sobreajuste, y capa de salida con 43 neuronas softmax

Rendimiento del modelo: 99,11% de accuracy en test

99.11%

Accuracy en test

Evaluado sobre el conjunto oficial de GTSRB

97.13%

Accuracy de validación

Mejor valor alcanzado durante el entrenamiento

0.0344

Loss en test


Pérdida muy baja, indicativa de alta confianza en las predicciones

11

Épocas entrenadas

EarlyStopping detuvo el entrenamiento en la época 11 de 15 máximas

Comparación con el baseline



Interpretación de los resultados

La mejora sobre el baseline es de **+93,45 puntos porcentuales**, lo que demuestra que la CNN aprendió representaciones robustas de las señales de tránsito.

El hecho de que el modelo se detuviera en la época 11 indica que convergió rápidamente sin sobreajuste, gracias al **EarlyStopping** y al **Dropout**.

- ✓ Un accuracy de 99,11% supera los estándares de muchos sistemas comerciales de asistencia a la conducción.

Diagnóstico profundo: precisión, recall y F1-score

Resultados globales del informe de clasificación

El modelo alcanzó valores **próximos a 0,99** en precision, recall y F1-score para la gran mayoría de las 43 clases, lo que confirma un rendimiento equilibrado y sin sesgos graves hacia clases mayoritarias.

Clases con menor rendimiento

Clase	F1-score	Motivo
Clase 0	~0,96	Pocas muestras
Clase 32	~0,96	Pocas muestras
Clase 41	~0,96	Pocas muestras

Interpretación de la matriz de confusión

La diagonal de la matriz de confusión estuvo casi completamente ocupada, evidenciando que los errores fueron **muy escasos y aislados**. Los pocos fallos se concentraron en clases visualmente similares con escasa representación.


 El modelo generaliza bien. Los errores se concentran en clases con menos representación, lo que apunta al desbalance como principal área de mejora futura.

Conclusión del análisis

La correlación entre **bajo rendimiento por clase** y **escasez de muestras** confirma que el desbalance del dataset es el factor limitante principal, no la arquitectura del modelo.

Inferencia sobre imágenes nuevas

Flujo de inferencia paso a paso



Salida del sistema

- Imagen original de la señal de tránsito
- Clase predicha con su nombre descriptivo

Ejemplo de predicción

"El modelo recibió una imagen nunca vista y predijo correctamente la señal con **alta confianza**, demostrando su capacidad de generalización en condiciones reales."

Este comportamiento valida que el sistema es apto para integrarse en un canal de conducción asistida, donde cada fotograma debe clasificarse de forma rápida y fiable.

Cierre: logros, limitaciones y próximos pasos

Logros alcanzados

- CNN entrenada con **98.87 % de accuracy** sobre 43 clases de señales de tránsito
- El **preprocesamiento estandarizado** fue clave para manejar la alta variabilidad de resoluciones del dataset
- Modelo **compacto (164.651 parámetros)**, válido como base para soluciones embebidas de conducción asistida
- El modelo supera al baseline en 93.2 puntos lo que demuestra que la red aprendió patrones reales y no solo memorizó la clase más común

Limitaciones identificadas

⚠ El **desbalance de clases** limita el rendimiento en categorías mino

- Puede fallar con imágenes donde la señal ocupa poco espacio dentro de la foto.
- Sensible a condiciones de baja iluminación o imágenes borrosas.
- Señales parcialmente tapadas o dañadas pueden clasificarse incorrectamente.
- El desbalance de clases afecta levemente el rendimiento en categorías con pocas imágenes.